

Implementasi Deep Learning Menggunakan CNN dan MobileNetV2 untuk Deteksi Indikasi Mikrosleep pada Pengemudi

Ranggapesty Ajisaputra

e-mail: 111202415874@mhs.dinus.ac.id

Abstrak

Mikrosleep merupakan kondisi hilangnya kesadaran dalam waktu singkat akibat kelelahan yang dapat meningkatkan risiko kecelakaan lalu lintas. Penelitian ini bertujuan untuk membandingkan performa model CNN Custom, MobileNetV2, dan MobileNetV2 hasil hyperparameter tuning dalam mendeteksi indikasi mikrosleep berdasarkan kondisi mata dan mulut. Dataset yang digunakan berasal dari Kaggle dan terdiri atas empat kelas, yaitu Closed_Eyes, Open_Eyes, No_yawn, dan Yawn. Metodologi penelitian meliputi Exploratory Data Analysis (EDA), preprocessing, pembagian data, augmentasi, pembangunan model, hyperparameter tuning, serta evaluasi menggunakan confusion matrix, precision, recall, F1-score, AUC, dan Grad-CAM. Hasil pengujian menunjukkan bahwa MobileNetV2 memperoleh performa terbaik dengan accuracy sebesar 93,85% dan F1-score sebesar 0,9385, diikuti MobileNetV2 hasil hyperparameter tuning dengan accuracy sebesar 92,76% dan CNN Custom dengan accuracy sebesar 33,74%. Penelitian ini menyimpulkan bahwa MobileNetV2 merupakan model yang paling optimal untuk mendeteksi indikasi mikrosleep berdasarkan kondisi mata dan mulut.

Kata kunci: mikrosleep, deep learning, MobileNetV2, transfer learning, Grad-CAM.

Abstract

Microsleep is a brief loss of consciousness caused by fatigue that may increase the risk of traffic accidents. This study aims to compare the performance of CNN Custom, MobileNetV2, and MobileNetV2 with hyperparameter tuning in detecting microsleep indications based on eye and mouth conditions. The dataset was obtained from Kaggle and consisted of four classes: Closed_Eyes, Open_Eyes, No_yawn, and Yawn. The research methodology included Exploratory Data Analysis (EDA), preprocessing, data splitting, augmentation, model development, hyperparameter tuning, and evaluation using confusion matrix, precision, recall, F1-score, AUC, and Grad-CAM. Experimental results show that MobileNetV2 achieved the best performance with an accuracy of 93.85% and an F1-score of 0.9385, followed by MobileNetV2 with hyperparameter tuning with an accuracy of 92.76%, and CNN Custom with an accuracy of 33.74%. This study concludes that MobileNetV2 is the most effective model for detecting microsleep indications based on eye and mouth conditions.

Keywords: mikrosleep, deep learning, MobileNetV2, transfer learning, Grad-CAM.

1. PENDAHULUAN

1.1 1.1 Latar Belakang

Kecelakaan lalu lintas masih menjadi salah satu permasalahan serius di berbagai negara, termasuk Indonesia. Salah satu faktor utama penyebab kecelakaan adalah menurunnya konsentrasi dan kewaspadaan pengemudi akibat kelelahan atau kantuk saat berkendara. Menurut data Kepolisian Republik Indonesia, angka kematian akibat kecelakaan lalu lintas pada tahun 2020 mencapai 23.529 jiwa atau setara dengan sekitar tiga korban meninggal setiap jam. Selain itu, sekitar 73% kecelakaan melibatkan kendaraan roda dua.

Kondisi mengantuk saat berkendara merupakan ancaman serius bagi keselamatan lalu lintas. Berdasarkan catatan National Sleep Foundation, sekitar 32% pengemudi setidaknya pernah mengalami satu kali kejadian mengemudi dalam keadaan mengantuk setiap bulan. Lebih lanjut, sekitar 25% kecelakaan lalu lintas disebabkan oleh pengemudi yang mengantuk. Mengemudi dalam kondisi lelah dapat menurunkan kemampuan fisiologis dan kognitif pengemudi, sehingga memengaruhi kemampuan dalam merespons situasi di jalan dan meningkatkan risiko kecelakaan.

Salah satu kondisi yang perlu diwaspadai adalah mikrosleep, yaitu keadaan ketika seseorang kehilangan kesadaran atau fokus dalam waktu singkat akibat kelelahan. Meskipun hanya berlangsung selama beberapa detik, mikrosleep dapat menyebabkan pengemudi kehilangan kendali terhadap kendaraan. Secara fisiologis, indikasi mikrosleep dapat diamati melalui perubahan pada kondisi mata dan mulut, seperti meningkatnya durasi mata tertutup, frekuensi kedipan, serta aktivitas menguap.

Seiring berkembangnya teknologi, berbagai metode telah dikembangkan untuk mendeteksi kantuk pengemudi. Penelitian sebelumnya memanfaatkan pendekatan seperti analisis Eye Aspect Ratio (EAR), Histogram of Oriented Gradients (HOG), Linear Support Vector Machine (SVM), hingga penggunaan Electroencephalography (EEG). Sistem berbasis HOG dan Linear SVM mampu mendeteksi kantuk pengemudi secara real-time dengan tingkat akurasi rata-rata sebesar 90,4%. Sementara itu, pendekatan berbasis EEG dilaporkan mampu mencapai akurasi hingga 95,24%. Namun, metode-metode tersebut masih memiliki beberapa keterbatasan, seperti kebutuhan perangkat tambahan, sensitivitas terhadap perubahan pencahayaan dan sudut pandang, serta keterbatasan dalam mengekstraksi pola visual yang kompleks.

Perkembangan deep learning dalam bidang computer vision membuka peluang untuk membangun sistem deteksi kantuk yang lebih akurat dan adaptif. Deep learning memungkinkan komputer mempelajari representasi visual secara otomatis tanpa memerlukan ekstraksi fitur manual. Salah satu arsitektur yang banyak digunakan dalam klasifikasi citra adalah Convolutional Neural Network (CNN). Akan tetapi, pelatihan CNN dari awal (*from scratch*) umumnya membutuhkan dataset yang besar dan waktu pelatihan yang panjang agar mampu menghasilkan performa yang optimal.

Sebagai alternatif, teknik transfer learning menawarkan solusi dengan memanfaatkan model yang telah dilatih pada dataset berskala besar, seperti ImageNet. Salah satu arsitektur yang banyak digunakan adalah MobileNetV2, yang dirancang untuk menghasilkan performa tinggi dengan kebutuhan komputasi yang relatif ringan melalui mekanisme *depthwise separable convolution*. Dengan menggunakan bobot yang telah dipelajari sebelumnya, MobileNetV2 mampu beradaptasi pada tugas baru meskipun hanya tersedia dataset dalam jumlah terbatas.

Berbagai penelitian sebelumnya umumnya hanya berfokus pada deteksi mata tertutup atau menggunakan klasifikasi biner antara kondisi mengantuk dan tidak mengantuk. Selain itu, implementasi sistem berbasis web interaktif yang mendukung proses inferensi secara real-time masih relatif terbatas. Oleh karena itu, penelitian ini mengimplementasikan dan membandingkan dua pendekatan deep learning, yaitu CNN Custom dan MobileNetV2 berbasis transfer learning, untuk mengklasifikasikan kondisi pengemudi ke dalam empat kelas, yaitu *Closed_Eyes*, *Open_Eyes*, *No_yawn*, dan *Yawn*. Selain melakukan perbandingan performa model, penelitian ini juga menerapkan hyperparameter tuning, interpretasi model menggunakan Grad-CAM, serta mengimplementasikan sistem ke dalam aplikasi web interaktif berbasis Streamlit yang dapat diakses secara daring.

2. KAJIAN PUSTAKA

2.1. Deep Learning

Deep learning merupakan cabang dari *machine learning* yang memanfaatkan jaringan saraf tiruan (*artificial neural network*) dengan banyak lapisan (*deep neural network*) untuk mempelajari pola dan representasi data secara otomatis. Berbeda dengan metode *machine learning* tradisional yang memerlukan ekstraksi fitur secara manual, *deep learning* mampu melakukan proses ekstraksi fitur dan klasifikasi secara bersamaan melalui proses pelatihan.

Perkembangan *deep learning* didukung oleh tiga faktor utama, yaitu meningkatnya ketersediaan dataset berskala besar, perkembangan kemampuan komputasi melalui penggunaan Graphics Processing Unit (GPU), serta munculnya berbagai arsitektur jaringan yang semakin efisien. Dalam bidang *computer vision*, *deep learning* telah digunakan secara luas pada berbagai aplikasi seperti klasifikasi citra, deteksi objek, pengenalan wajah, segmentasi citra, hingga sistem kendaraan otonom. Pada penelitian ini, *deep learning* digunakan untuk mengklasifikasikan kondisi pengemudi ke dalam empat kelas, yaitu *Closed_Eyes*, *Open_Eyes*, *No_yawn*, dan *Yawn*.

2.2. Computer Vision

Computer vision merupakan cabang ilmu komputer yang bertujuan untuk memungkinkan komputer memahami, menganalisis, dan menafsirkan informasi visual dari gambar maupun video. Tujuan utama *computer vision* adalah mengembangkan sistem yang mampu mengenali lingkungan di sekitarnya dengan cara yang menyerupai penglihatan manusia.

2.3. Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan arsitektur *deep learning* yang dirancang khusus untuk memproses data berbentuk grid, seperti gambar. CNN mampu mempelajari fitur visual secara otomatis melalui serangkaian lapisan konvolusi dan pooling.

2.4. MobileNetV2

MobileNetV2 merupakan arsitektur CNN ringan yang dikembangkan oleh Google pada tahun 2018. Arsitektur ini dirancang untuk perangkat dengan sumber daya komputasi terbatas, seperti ponsel dan sistem *embedded*. Keunggulan utama MobileNetV2 adalah penggunaan teknik *depthwise separable convolution*, yang memisahkan proses konvolusi spasial dan pencampuran kanal sehingga jumlah parameter dan operasi komputasi dapat dikurangi secara signifikan.

2.5. Transfer Learning

Transfer learning merupakan teknik yang memanfaatkan model yang telah dilatih sebelumnya pada dataset besar untuk menyelesaikan tugas baru. Pada penelitian ini, MobileNetV2 yang telah dilatih menggunakan dataset ImageNet digunakan sebagai *feature extractor*. Seluruh bobot pada lapisan dasar dibekukan (*frozen*), sedangkan lapisan klasifikasi baru dilatih menggunakan dataset deteksi kantuk.

2.6. Hyperparameter Tuning

Hyperparameter merupakan parameter yang ditentukan sebelum proses pelatihan dimulai dan tidak dipelajari secara otomatis oleh model. Penelitian ini menggunakan metode *Random Search* untuk mencari kombinasi hyperparameter terbaik. Hyperparameter yang digunakan ditunjukkan pada tabel berikut.

2.7. Penelitian Terkait (State of The Art)

Gradient-weighted Class Activation Mapping (Grad-CAM) merupakan salah satu metode interpretasi pada model *deep learning* yang digunakan untuk mengetahui area gambar yang paling berpengaruh terhadap hasil prediksi model. Metode ini menghasilkan visualisasi berupa *heatmap* yang menunjukkan bagian-bagian citra yang menjadi fokus model ketika melakukan klasifikasi. Grad-CAM bekerja dengan menghitung gradien dari kelas target terhadap *feature map* pada lapisan konvolusi terakhir, kemudian menggunakan informasi tersebut untuk menentukan tingkat kepentingan setiap area pada gambar.

Proses Grad-CAM dimulai dengan memasukkan citra ke dalam model untuk memperoleh prediksi kelas. Selanjutnya, gradien dari skor kelas terhadap *feature map* pada lapisan konvolusi terakhir dihitung dan dirata-ratakan untuk memperoleh bobot masing-masing *feature map*. Bobot tersebut kemudian dikombinasikan dengan *feature map* sehingga menghasilkan *heatmap* yang dapat ditampilkan di atas gambar asli.

Penggunaan Grad-CAM sangat penting dalam penelitian berbasis *deep learning* karena dapat membantu menjelaskan alasan di balik keputusan model. Dengan visualisasi ini, peneliti dapat memverifikasi apakah model benar-benar memperhatikan area yang relevan atau justru memanfaatkan pola lain yang tidak diinginkan. Dalam penelitian ini, Grad-CAM digunakan untuk memastikan bahwa model memusatkan perhatian pada area mata saat mengklasifikasikan kelas *Closed Eyes* dan *Open Eyes*, serta pada area mulut saat mengklasifikasikan kelas *No yawn* dan *Yawn*. Hasil visualisasi tersebut digunakan sebagai bentuk interpretasi dan validasi terhadap performa model yang dikembangkan.

2.8. Penelitian Terkait (State of The Art)

Evaluasi model dilakukan menggunakan beberapa metrik berikut.

1. Accuracy

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

2. Precision

$$Precision = \frac{TP}{TP + FN}$$

3. Recall

$$Recall = \frac{TP}{TP + FN}$$

4. F1-Score

$$F1 - Score = \frac{Precision \times Recall}{Precision + Recall}$$

5. ROC-AUC

ROC (*Receiver Operating Characteristic*) digunakan untuk mengukur kemampuan model dalam membedakan setiap kelas.

6. Confusion Matrix


Confusion matrix merupakan metode evaluasi yang menunjukkan jumlah prediksi benar dan salah pada setiap kelas. Paper yang kamu unggah juga menggunakan *confusion matrix* untuk mengevaluasi sistem deteksi kantuk.

2.9. Penelitian Terkait (State of The Art)

Streamlit merupakan *framework open-source* berbasis Python yang digunakan untuk membangun aplikasi web interaktif, khususnya pada bidang *machine learning* dan *data science*. Streamlit memungkinkan pengembang membuat antarmuka web tanpa perlu menggunakan HTML, CSS, atau JavaScript. Pada penelitian ini, Streamlit digunakan untuk melakukan *deployment* model deteksi indikasi mikrosleep sehingga pengguna dapat melakukan pengujian melalui fitur unggah gambar, kamera, dan deteksi *real-time*.

3. METODOLOGI PENELITIAN

Dalam penelitian ini, pengembangan sistem deteksi indikasi *mikrosleep* pada pengemudi dilakukan melalui beberapa tahapan yang saling berkaitan untuk menghasilkan model yang memiliki performa yang baik dan dapat diimplementasikan pada aplikasi berbasis web. Metode penelitian yang digunakan mengikuti alur pengembangan *deep learning* yang dimulai dari proses pengumpulan dataset, *Exploratory Data Analysis* (EDA), *preprocessing*, pembagian data (*data splitting*), augmentasi data, pembangunan model menggunakan CNN Custom dan MobileNetV2, *hyperparameter tuning*, evaluasi model, hingga tahap *deployment* menggunakan Streamlit. Setiap tahapan memiliki tujuan yang berbeda, mulai dari memahami karakteristik dataset dan mempersiapkan data agar sesuai dengan kebutuhan model, hingga proses pelatihan menggunakan data latih dan validasi untuk memperoleh model terbaik. Model yang dihasilkan kemudian dievaluasi menggunakan beberapa metrik, seperti *confusion matrix*, ROC Curve, *classification report*, dan Grad-CAM. Tahap terakhir adalah implementasi model ke dalam aplikasi berbasis web sehingga sistem dapat digunakan untuk mendeteksi indikasi *mikrosleep* secara *real-time*. Alur penelitian secara keseluruhan ditunjukkan pada Gambar 1.



Gambar 1 Alur Penelitian

3.1. Pengumpulan Data

Tahap pertama dalam penelitian ini adalah pengumpulan data yang digunakan untuk melatih dan mengevaluasi model deteksi indikasi *mikrosleep*. Dataset yang digunakan diperoleh dari platform Kaggle dan terdiri atas citra area mata dan mulut yang telah dikelompokkan ke dalam empat kelas, yaitu *Closed_Eyes*, *Open_Eyes*, *No_yawn*, dan *Yawn*. Dataset tersebut dipilih karena memiliki variasi data yang cukup untuk merepresentasikan kondisi pengemudi yang mengantuk maupun tidak mengantuk.

Table 1 Distribusi dataset

Kelas	Jumlah Data
Closed_Eyes	2.726
Open_Eyes	2.726
No_yawn	3.089
Yawn	3.025
Total	11.566

3.2. Exploratory Data Analysis (EDA)

Setelah proses pengumpulan data, dilakukan tahap Exploratory Data Analysis (EDA) untuk memahami karakteristik dataset sebelum digunakan dalam proses pelatihan model. Analisis dilakukan terhadap distribusi kelas, format file, contoh citra, serta ukuran gambar pada setiap kelas. Hasil analisis menunjukkan bahwa dataset terdiri atas dua format gambar, yaitu JPEG dan PNG. Sebanyak 65,4% data menggunakan format JPEG, sedangkan 34,6% sisanya menggunakan format PNG. Selain itu, berdasarkan sampel data yang dianalisis, resolusi gambar bervariasi secara signifikan, dengan ukuran berkisar antara 28×21 piksel hingga 146×138 piksel. Tahap EDA bertujuan untuk mengidentifikasi karakteristik dataset dan menentukan langkah preprocessing yang diperlukan sebelum proses pelatihan model dilakukan.

3.3. Preprocessing

Tahap *preprocessing* dilakukan untuk menyiapkan data agar sesuai dengan kebutuhan model *deep learning*. Proses yang dilakukan meliputi perubahan ukuran gambar (*resize*) menjadi 64×64 piksel, normalisasi nilai piksel, serta konversi gambar ke format RGB. Proses normalisasi dilakukan untuk menyamakan rentang nilai piksel sehingga proses pelatihan dapat berlangsung lebih stabil. Tahap ini bertujuan untuk menghasilkan data masukan yang seragam dan mengurangi pengaruh perbedaan ukuran maupun format gambar pada dataset.

3.4. Split Data (Pembagian data)

Setelah tahap *preprocessing*, dataset dibagi menjadi tiga bagian, yaitu data latih (*training set*), data validasi (*validation set*), dan data uji (*test set*). Pembagian data dilakukan dengan rasio 74%, 13%, dan 13%.


Table 2 Split Data

Dataset	Jumlah Data
Training Set	8.548
Validation Set	1.554
Test Set	1.464
Total	11.566

Data latih digunakan untuk melatih model, data validasi digunakan selama proses pelatihan, sedangkan data uji digunakan untuk mengevaluasi performa akhir model.

3.5. Evaluasi (Akurasi, ROC-AUC, PR-AUC, Uji signifikansi)

Augmentasi data dilakukan pada data latih untuk meningkatkan variasi dataset dan mengurangi risiko *overfitting*. Teknik augmentasi yang diterapkan meliputi rotasi hingga $\pm 20^\circ$, *width shift* dan *height shift* sebesar 10%, *zoom* sebesar 10%, serta penyesuaian tingkat kecerahan pada rentang 0,8–1,2. Proses ini bertujuan untuk menghasilkan variasi citra baru tanpa mengubah informasi utama pada gambar sehingga model dapat mempelajari pola yang lebih beragam.



Gambar 2 Perbandingan citra asli dan hasil augmentasi pada setiap kelas

Gambar 3.5 menunjukkan perbandingan antara citra asli dan beberapa citra hasil augmentasi pada setiap kelas. Hasil augmentasi menghasilkan variasi data baru dengan perubahan posisi, ukuran, dan tingkat pencahayaan, tetapi tetap mempertahankan karakteristik utama dari objek yang diamati. Dengan demikian, model diharapkan mampu mengenali pola dengan lebih baik dan lebih tahan terhadap variasi data pada kondisi nyata.

3.6. Pembangunan Model

Pada penelitian ini, proses pembangunan model dilakukan menggunakan dua arsitektur *deep learning*, yaitu CNN Custom dan MobileNetV2 berbasis *transfer learning*. Kedua model dilatih menggunakan data latih dan dievaluasi menggunakan data validasi pada setiap *epoch* untuk memperoleh model dengan performa terbaik. Model CNN Custom dibangun menggunakan dua lapisan *convolutional* dengan jumlah filter masing-masing sebesar 32 dan 64 yang diikuti oleh lapisan *max pooling* untuk mengurangi dimensi fitur. Selanjutnya, hasil ekstraksi fitur diratakan menggunakan lapisan *flatten* dan diteruskan ke lapisan *dense* yang terdiri dari 128 neuron. Untuk mengurangi risiko *overfitting*, digunakan lapisan *dropout* sebesar 0,5 sebelum lapisan keluaran (*output layer*) yang menggunakan fungsi aktivasi *softmax* untuk mengklasifikasikan citra ke dalam empat kelas.

Selain CNN Custom, penelitian ini juga menerapkan model MobileNetV2 menggunakan pendekatan *transfer learning* dengan memanfaatkan bobot awal (*pretrained weights*) dari dataset ImageNet. Lapisan dasar (*base model*) dibekukan (*frozen*) sehingga hanya lapisan klasifikasi yang dilatih menggunakan dataset penelitian. Arsitektur klasifikasi terdiri atas lapisan *Global Average Pooling*, lapisan *dense*, *dropout* sebesar 0,5, dan lapisan keluaran dengan fungsi aktivasi *softmax*. Penggunaan MobileNetV2 dengan *transfer learning* memungkinkan proses pelatihan hanya dilakukan pada lapisan klasifikasi yang

memiliki jumlah parameter lebih sedikit dibandingkan CNN Custom, sehingga diharapkan mampu menghasilkan performa yang lebih baik dengan kebutuhan komputasi yang lebih efisien.

3.7. Hyperparameter Tuning

Setelah proses pembangunan model, dilakukan *hyperparameter tuning* pada model MobileNetV2 untuk memperoleh kombinasi parameter yang optimal. Proses ini dilakukan menggunakan metode *Random Search*, yaitu metode pencarian yang menguji berbagai kombinasi parameter secara acak dari ruang pencarian yang telah ditentukan. Tujuan dari tahap ini adalah untuk meningkatkan performa model serta menentukan konfigurasi yang paling sesuai dengan karakteristik dataset yang digunakan.

Parameter yang diuji pada proses *hyperparameter tuning* meliputi *learning rate* sebesar 0,0001, 0,0005, dan 0,001; jumlah neuron pada lapisan *dense* sebesar 64, 128, dan 256; nilai *dropout* sebesar 0,3, 0,5, dan 0,7; jenis *optimizer* berupa Adam dan RMSprop; serta *batch size* sebesar 16 dan 32. Penelitian ini merencanakan sebanyak 20 percobaan (*trial*), namun hanya 12 *trial* yang berhasil diselesaikan. Setiap kombinasi parameter dilatih menggunakan data latih dan dievaluasi menggunakan data validasi untuk menentukan konfigurasi model terbaik. Hasil dari proses *hyperparameter tuning* akan dibahas lebih lanjut pada bab berikutnya.

3.8. Evaluasi Model

Tahap evaluasi dilakukan untuk mengukur kemampuan model dalam melakukan klasifikasi terhadap data yang belum pernah digunakan pada proses pelatihan. Evaluasi dilakukan menggunakan data uji (*test set*) untuk mengetahui tingkat performa model yang telah dibangun. Pada penelitian ini, evaluasi diterapkan pada model CNN Custom dan MobileNetV2, termasuk model hasil *hyperparameter tuning*.

Beberapa metrik evaluasi yang digunakan meliputi *accuracy*, *precision*, *recall*, dan *F1-score* yang diperoleh melalui *classification report*. Selain itu, digunakan *confusion matrix* untuk melihat distribusi prediksi pada setiap kelas serta *Receiver Operating Characteristic* (ROC) *curve* untuk menganalisis kemampuan model dalam membedakan masing-masing kelas. Penelitian ini juga memanfaatkan metode *Gradient-weighted Class Activation Mapping* (Grad-CAM) untuk memvisualisasikan bagian citra yang menjadi fokus model dalam proses pengambilan keputusan. Hasil evaluasi dari seluruh model akan dibahas lebih lanjut pada bab berikutnya.

3.9. Evaluasi Model


Tahap *deployment* dilakukan untuk mengimplementasikan model terbaik ke dalam sebuah aplikasi berbasis web sehingga dapat digunakan untuk mendeteksi indikasi *microsleep* secara langsung. Pada penelitian ini, proses *deployment* dilakukan menggunakan framework Streamlit yang dipilih karena kemudahannya integrasinya dengan model *machine learning* berbasis Python serta kemampuannya dalam membangun antarmuka interaktif.

Aplikasi yang dikembangkan menyediakan beberapa fitur utama, seperti unggah gambar (*image upload*), pengambilan gambar menggunakan kamera, serta deteksi secara *real-time*. Selain itu, aplikasi juga dilengkapi dengan sistem peringatan berupa alarm yang akan aktif ketika model mendeteksi kondisi yang mengindikasikan *microsleep*. Implementasi aplikasi ini bertujuan untuk mempermudah pengguna dalam melakukan pengujian model serta menunjukkan penerapan model pada skenario penggunaan nyata. Hasil implementasi aplikasi akan dibahas lebih lanjut pada bab berikutnya.

4. HASIL DAN PEMBAHASAN

Penelitian ini bertujuan untuk mengevaluasi dan membandingkan performa model CNN Custom, MobileNetV2, dan MobileNetV2 hasil *hyperparameter tuning* dalam mendeteksi indikasi *microsleep* berdasarkan kondisi mata dan mulut. Evaluasi dilakukan menggunakan beberapa metrik, seperti *confusion matrix*, *classification report*, kurva ROC-AUC, serta visualisasi *Grad-CAM*. Selain itu, dilakukan analisis terhadap pengaruh proses *hyperparameter tuning* untuk memperoleh model dengan performa terbaik yang akan diimplementasikan pada aplikasi berbasis web.


Proses *hyperparameter tuning* dilakukan menggunakan metode *Random Search* dengan menguji berbagai kombinasi *learning rate*, jumlah neuron pada lapisan *dense*, nilai *dropout*, jenis *optimizer*, dan *batch size*. Sebanyak 12 *trial* berhasil dijalankan dan menghasilkan performa yang berbeda pada setiap kombinasi parameter.



Gambar 3 Hasil hyperparameter tuning model MobileNetV2

Berdasarkan Gambar 3, seluruh *trial* menghasilkan akurasi validasi yang relatif tinggi dengan rentang nilai sekitar 94% hingga 97%. Grafik sebelah kiri menunjukkan perbandingan akurasi terbaik yang diperoleh pada setiap *trial*, sedangkan grafik sebelah kanan memperlihatkan hubungan antara nilai *learning rate* dan akurasi validasi yang dihasilkan. Berdasarkan hasil tersebut, konfigurasi terbaik kemudian digunakan pada tahap evaluasi model.

Evaluasi model dilakukan menggunakan *confusion matrix* untuk mengetahui kemampuan masing-masing model dalam mengklasifikasikan setiap kelas, yaitu *Closed_Eyes*, *Open_Eyes*, *No_yawn*, dan *Yawn*. *Confusion matrix* menyajikan perbandingan antara label sebenarnya (*true label*) dan hasil prediksi model (*predicted label*). Nilai yang berada pada diagonal utama menunjukkan jumlah prediksi yang benar, sedangkan nilai di luar diagonal menunjukkan kesalahan klasifikasi yang dilakukan oleh model.




Gambar 4 Confusion Matrix

Berdasarkan Gambar 4, model CNN Custom menunjukkan performa yang paling rendah dengan nilai akurasi sebesar 33,74%. Model ini cenderung memprediksi sebagian besar data ke kelas *Yawn*, sehingga banyak data pada kelas *Closed_Eyes*, *Open_Eyes*, dan *No_yawn* yang salah diklasifikasikan. Hal tersebut menunjukkan bahwa model CNN Custom belum mampu mempelajari pola dari dataset dengan baik.

Sebaliknya, model MobileNetV2 dan MobileNetV2 hasil *hyperparameter tuning* menunjukkan performa yang jauh lebih baik. Kedua model mampu mengklasifikasikan sebagian

besar data dengan benar, yang ditunjukkan oleh dominasi nilai pada diagonal utama matriks. MobileNetV2 memperoleh akurasi tertinggi sebesar 93,85%, sedangkan MobileNetV2 hasil *hyperparameter tuning* memperoleh akurasi sebesar 92,76%. Kesalahan klasifikasi pada kedua model umumnya terjadi antara kelas *No_yawn* dan *Yawn*, yang memiliki karakteristik visual yang relatif mirip.

Selain menggunakan *confusion matrix*, evaluasi model juga dilakukan menggunakan kurva *Receiver Operating Characteristic* (ROC) untuk mengukur kemampuan model dalam membedakan setiap kelas. Nilai *Area Under the Curve* (AUC) yang mendekati 1 menunjukkan bahwa model memiliki kemampuan diskriminasi yang baik, sedangkan garis diagonal merepresentasikan performa klasifikasi acak.



Gambar 5 Kurva ROC

Berdasarkan Gambar 5, model CNN Custom menghasilkan nilai AUC yang lebih rendah dibandingkan dua model lainnya, khususnya pada kelas *Open_Eyes* dan *No_yawn*. Hal ini sejalan dengan hasil *confusion matrix* yang menunjukkan bahwa model CNN Custom masih mengalami banyak kesalahan klasifikasi.

Sementara itu, model MobileNetV2 dan MobileNetV2 hasil *hyperparameter tuning* menunjukkan performa yang sangat baik dengan seluruh nilai AUC berada di atas 0,98. MobileNetV2 memperoleh nilai AUC sebesar 0,995 untuk kelas *Closed_Eyes*, 0,999 untuk kelas *Open_Eyes*, 0,990 untuk kelas *No_yawn*, dan 0,992 untuk kelas *Yawn*. Adapun model MobileNetV2 hasil *hyperparameter tuning* memperoleh nilai AUC sebesar 0,993, 0,998, 0,988, dan 0,989 untuk masing-masing kelas.

Rekapitulasi menyeluruh dari seluruh metrik evaluasi ketiga model disajikan pada Tabel 4.1.

Tabel 3 Hasil Evaluasi Model

Model	Accuracy	Precision	Recall	F1-Score
CNN Custom	33,74%	0,5099	0,3374	0,2094
MobileNetV2	93,85%	0,9394	0,9385	0,9385
MobileNetV2 Tuned	92,76%	0,9286	0,9276	0,9275

Berdasarkan Tabel 4.1, model MobileNetV2 menghasilkan performa terbaik dengan nilai *accuracy* sebesar 93,85%, *precision* sebesar 0,9394, *recall* sebesar 0,9385, dan *F1-score* sebesar 0,9385. Sementara itu, model MobileNetV2 hasil *hyperparameter tuning* memperoleh performa yang sedikit lebih rendah dengan *accuracy* sebesar 92,76%. Di sisi lain, model CNN Custom menunjukkan performa yang jauh di bawah kedua model lainnya dengan nilai *F1-score* sebesar 0,2094.

Secara keseluruhan, hasil evaluasi menunjukkan bahwa penggunaan *transfer learning* pada MobileNetV2 mampu meningkatkan kemampuan model dalam mengenali pola pada dataset dibandingkan pendekatan CNN Custom. Selain itu, proses *hyperparameter tuning* tidak memberikan peningkatan performa pada penelitian ini karena model MobileNetV2 tanpa *tuning* justru menghasilkan akurasi yang lebih tinggi.

5. KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, dapat disimpulkan bahwa model *deep learning* berbasis *transfer learning* menggunakan MobileNetV2 mampu memberikan performa yang lebih baik dibandingkan model CNN Custom dalam mendeteksi indikasi *microsleep* berdasarkan kondisi mata dan mulut. Model MobileNetV2 memperoleh nilai *accuracy* sebesar 93,85%, *precision* sebesar 0,9394, *recall* sebesar 0,9385, dan *F1-score* sebesar 0,9385, sedangkan model CNN Custom hanya memperoleh nilai *accuracy* sebesar 33,74% dan *F1-score* sebesar 0,2094.

Proses *hyperparameter tuning* menggunakan metode *Random Search* berhasil menghasilkan model dengan performa yang kompetitif. Namun, model MobileNetV2 hasil *hyperparameter tuning* memperoleh nilai *accuracy* sebesar 92,76%, yang sedikit lebih rendah dibandingkan model MobileNetV2 tanpa *tuning*. Hasil tersebut menunjukkan bahwa penerapan *hyperparameter tuning* tidak selalu menghasilkan peningkatan performa dan sangat bergantung pada kombinasi parameter yang digunakan.

Berdasarkan hasil evaluasi menggunakan *confusion matrix*, kurva ROC, *classification report*, dan visualisasi Grad-CAM, model MobileNetV2 menunjukkan kemampuan klasifikasi yang sangat baik pada keempat kelas, yaitu *Closed_Eyes*, *Open_Eyes*, *No_yawn*, dan *Yawn*. Selain itu, nilai AUC yang mendekati 1 pada seluruh kelas menunjukkan bahwa model memiliki kemampuan diskriminasi yang tinggi dalam membedakan setiap kategori.

Model terbaik kemudian berhasil diimplementasikan ke dalam aplikasi berbasis web menggunakan Streamlit yang dilengkapi dengan fitur unggah gambar, kamera, deteksi *real-time*, dan sistem peringatan berupa alarm. Dengan demikian, penelitian ini menunjukkan bahwa pendekatan *deep learning* berbasis MobileNetV2 memiliki potensi untuk diterapkan sebagai sistem pendeteksi indikasi *microsleep* pada pengemudi secara efektif.
